

SAé – BUT Informatique

Analyse comparative de la pollution atmosphérique en France et en Chine

Projet - Niveau Licence

Contexte :

La pollution atmosphérique est un enjeu majeur pour l'environnement et la santé publique dans les grandes métropoles. Ce projet vise à analyser et à comparer les niveaux de pollution atmosphérique dans trois grandes métropoles : la région parisienne, en France, d'un côté, et Pékin et Shanghai, en Chine, de l'autre. Du point de vue technique, il s'agit de mettre en place une base de données et de l'exploiter pour explorer les niveaux de qualité de l'air dans les régions concernées, tout en mettant en évidence les tendances globales et les différences.

Objectifs et étapes :

1. Extraction et chargement des données : on se base sur des données publiques d'observation de la qualité de l'air en France (ici le 20^{ème} arrondissement de Paris et la ville de Versailles) et en Chine (à Pékin et à Shanghai). *Les données d'intérêt ont été téléchargées et une partie vous est fournie via l'ENT (un descriptif est fourni en annexe de ce document).* Vous devez, dans un premier temps, consulter ces fichiers et documents afin d'en identifier l'organisation, le type de données, les polluants couverts, etc. Vous remarquerez, par exemple, que les données chinoises comportent plusieurs mesures (particules, gaz, relevés de température, etc.), tandis que celles de la région parisienne sont limitées au dioxyde d'azote (NO₂) dont le niveau reste préoccupant en France, et que la structuration des données diffère entre les deux sources. Ensuite, vous devez extraire ces données et les charger dans la base de données. Pour simplifier le process, j'ai préparé des scripts SQL prêts à l'emploi pour créer et charger les données de mesure chinoises. Utilisez-les. Ensuite, importez les données françaises à partir de fichiers csv.

Indication : Utilisez l'interface d'import/export de fichier CSV du SGBD.

2. Transformation de la base de données : Proposez un schéma relationnel simple et homogène pour l'ensemble des données, puis convertissez les données originales dans ce schéma. Par exemple, vous pouvez garder telle quelle la structure des données chinoises (stations et mesures de la qualité de l'air), définir un schéma équivalent pour les données françaises restreint au NO₂, puis créer des vues pour faciliter les requêtes portant sur des données de même type.

Attention : *les types de données ne sont pas toujours correctement identifiés lors de l'importation (en raison des paramètres régionaux relatifs au point décimal ou à la date). Utilisez les fonctions de conversion de type appropriées pour transférer les données vers de nouvelles tables.*

3. Visualisation des données sous Python :

- Donnez les périodes couvertes et les statistiques de base (min, max...) des mesures par ville.
- Visualisez les courbes pour une station particulière de Shanghai, pour un jour donné, puis la moyenne journalière pour les mois de juillet et de décembre à Pékin. Utilisez les seuils d'AQI pour qualifier l'impact de la pollution (faible, modéré, etc.) au cours de ces deux mois et illustrez-le graphiquement.

4. Analyse statistique avancée en SQL avec visualisation sous Python :

- Donnez des statistiques : min, max, médiane, quantiles, variance, écart interquartile, par station, par ville, pour toute période confondue ; puis par ville et par mois.
- Proposez une méthode pour analyser les données sur toutes leurs dimensions : géographiques, temporelles. Définir les vues nécessaires dans la base de données et les graphiques correspondants.

- Analysez les données par ville à différentes échelles temporelles.
- Identifiez les stations présentant le plus de valeurs manquantes. Identifier les périodes sans données. Que faire de ces stations ou de ces périodes dans vos analyses ?
- Lissez les mesures en calculant des moyennes mobiles.
- Générez des graphiques comparant les niveaux de pollution entre les stations, les villes et les pays.
- Calculez le nombre de jours de dépassement des valeurs réglementaires (selon l'OMS) dans le 20^{ème} arrondissement et dans les villes chinoises dans les périodes couvertes par les données.

Méthodes et outils :

1. Création de la base de données, ici sous Oracle
2. Analyse et Visualisation :
 - par des requêtes SQL pour analyser les données (moyennes, pics de pollution, tendances saisonnières).
 - avec des outils de visualisation (bibliothèques Python telles que *matplotlib*, *seaborn* et *folium*) pour créer des graphiques et des cartes.

Livrables attendus:

- L1.** Un rapport décrivant le processus de création et de chargement de la base de données (objectif 1)
- L2.** Un rapport sur la conception du schéma cible et des scripts de transformation vers ce schéma cible (objectif 2)
- L3.** Une première analyse visuelle des mesures de NO₂, ville par ville, en choisissant judicieusement les périodes (objectif 3)
- L4.** Un rapport d'analyse documenté comprenant les requêtes, les courbes et autres graphiques (testez-en plusieurs) permettant de comparer la pollution entre les stations, les villes, les pays et les périodes : saisons, semaine versus week-end, etc. (objectif 4)
- L5.** Une présentation orale et une démonstration du résultat du projet. On entend ici le bilan de vos analyses de la qualité de l'air en France et en Chine, avec vos interprétations et l'identification d'éventuelles limites de vos résultats.

Échéancier :

Ce projet représente 16 h de travail réparties sur 4 semaines.

- **L1** et **L2** sont à remettre la 1^{ère} semaine
- **L3** pour la 2^{ème} semaine
- **L4** pour la fin de la 4^{ème} semaine
- **L5** démonstrations et soutenances (10 minutes par binôme) lors des séances de TP qui suivra

Annexe - Données fournies

Voici la liste des données fournies et leur description :

➤ Pour la France (dossier QA_France)

Fichier : **respiron-mieux-dans-le-20eme-donnees-mini-stations.csv**

Description : Mesures de la qualité de l'air en 2019 (limitées ici à la période de juillet à décembre) focalisées sur le NO2 dans le 20^{ème} arrondissement dans le cadre d'un projet avec 9 stations dans des environnements plus ou moins exposés à la pollution.

Extrait du fichier :

index	Date et heure de la mesure	Père Lachaise	Parc de Belleville	Bd Ménilmontant	Stade Louis Lumière	Rue Ménilmontant	Rue des Pyrénées	Place St Fargeau	Echangeur A3/BP	Station Référence - BP Est	Station Référence - Paris 18 ^{ème}
5923	2019-09-04T19:00:00+02:00	10.0029466667	2.2402266667	16.9944392063	14.7346402423	17.6285647893	25.2578189568	25.8922652876	29.2821984504	11.5	9.4
2975	2019-05-04T23:00:00+02:00	10.0054985493		20.5793690764	16.437829512		24.0446159449	26.294258867	25.6348506245	26.2	42.1

Fichier : **Stations_Paris20.csv**

Description : Adresses, description et localisation des 9 stations de mesure du projet « respiron mieux dans le 2^{ème} »

Informations supplémentaires : **RespironsMieux_FormationQA.pdf** dans le dossier fourni « Ressources_documents »

Contenu di fichier :

Station	Description	lat	lon	TypePollution
Place Saint-Fargeau Paris	Petite place à proximité du trafic	48.871495749999994	2.403993775450449	moyen
Parc de Belleville Paris	Fond urbain caractérisé par un niveau de pollution minimum	48.87154835	2.3842289610211114	bas
Rue de Belleville Paris	Rue en pente et fréquentée de type canyon	48.87311156	2.3812171	moyen
Rue des Pyrénées Paris	Rue en pente et fréquentée de type canyon	48.8526039	2.4061213	moyen
Échangeur du Boulevard Périphérique Paris	Site caractérisé par un niveau de pollution maximale	48.8645603	2.4119582	haut
Cimetière du Père Lachaise Paris	Fond urbain caractérisé par un niveau de pollution minimum	48.861129649999995	2.394008682270477	bas
Stade Louis Lumière Paris	Espace vaste situé à proximité du périphérique	48.8574274	2.4115482	moyen
Rue Frédéric Loliée Paris	Rue résidentielle calme à faible trafic	48.8494388	2.4057871	bas
Grande station BP EST Airparif Paris 12	Station située à proximité du matériel de référence utilisée par Airparif pour vérifier le bon fonctionnement des mini-stations	48.8379114	2.410369	haut
8 rue de Limoges Versailles, France	Périurbain	48.7991067	2.1318172	moyen

Fichier : **Versailles_NO2_2019.csv**

Description : Mesures de la qualité de l'air de juillet – décembre 2019 focalisées sur les NOX d'une station à Versailles.

Extrait du fichier :

horodatage,NO2,NO,NOX,O3

2019-07-01 00:00:00Z,4.8,0.8,5.9,58.2

2019-07-01 01:00:00Z,4.3,0.6,5.2,57.7

➤ Pour la Chine (dossier QA_Chine)

Les données correspondent aux mesures de la qualité de l'air collectées aux stations d'observation situées à Pékin et à Shanghai. Elles couvrent une période d'un an, du 2 août 2013 au 2 août 2014. Elles sont fournies dans deux dossiers séparés, chacun contenant deux fichiers : "Station.txt" et "CrawledData.txt" dont la spécification est la suivante.

Fichier : **CrawledData.txt**

Description : Contient les mesures proprement dites par station. Elles sont horodatées et exprimées en indice de qualité de l'air (*AQI* pour *Air Quality Index*) selon le standard chinois¹. Il décrit les valeurs de PM2.5 et de PM10 (particules fines de taille 2,5 et 10 microns respectivement), le NO2 (dioxyde d'azote), la température en degrés Celsius, l'humidité relative, la vitesse du vent (en km/h) et le temps qu'il fait (Neigeux = 0, Nuageux = 1, Ensoleillé = 2, Couvert = 3, Pluvieux = 4, Brumeux = 5, Poussiéreux = 6). Voici l'en-tête :

station_id	time	PM25_AQI_value	PM10_AQI_value	NO2_AQI_value	temperature	pressure	humidity	wind	weather
------------	------	----------------	----------------	---------------	-------------	----------	----------	------	---------

Extrait fourni : ECHANTILLON_MESURES_PKIN.sql et ECHANTILLON_MESURES_SHANGHAI.sql (dans chacun des dossiers Beijing et Shanghai), limité aux mesures de la qualité de l'air d'une station de la ville correspondante (stations en ligne). Le format est le même qu'un fichier csv

Fichier : **Station.txt** (dans chacun des dossiers Beijing et Shanghai)

Description : Décrit les stations de mesure par leur identifiant, leur nom et leur position, composée de la latitude et de la longitude. Voici l'en-tête :

station_id	station_name	latitude	longitude
------------	--------------	----------	-----------

Informations supplémentaire : voir le document Data_Description_China.docx fourni

¹ L'indice AQI est associé aux seuils selon le standard GB3095-2012 : Excellent ($AQI \leq 50$), Bon ($AQI \leq 100$), Pollution légère ($AQI \leq 150$), Pollution modérée ($AQI \leq 200$), Pollution forte ($AQI \leq 300$) et Pollution sévère ($AQI > 300$). Pour le NO2, il faudrait convertir les données en $\mu\text{g}/\text{m}^3$ ($1\text{ppm} = 1,9 \mu\text{g}/\text{m}^3$)
Le standard chinois (GB3095-2012) est plus tolérant que celui de l'OMS utilisé notamment en France.
Voir <https://tourisme-chine.com/pollution-en-chine/>

Pour aller plus loin...

Outre les données fournies, il est recommandé de consulter les sources de ces données ainsi que les portails spécialisés afin de comprendre le contexte de cette mise en situation. Voici les principaux :

➤ **Région Parisienne :**

- L'étude menée dans le 20^{ème} arrondissement de Paris en 2019 à l'aide de mini-stations de la qualité de l'air a été publiée ici : <https://opendata.paris.fr/explore/dataset/respirons-mieux-dans-le-20eme-donnees-mini-stations/information>

- AirParif : l'association agréée surveillance de la qualité de l'air (AASQA) en Île-de-France fournit des données historiques et en temps réel sur les principaux polluants (PM2.5, PM10, NO2, O3, etc.). On peut y accéder en téléchargement (ex. CSV) ou via une API. <https://www.airparif.asso.fr/>

- OpenData Paris : La ville de Paris propose également des jeux de données sur la qualité de l'air. <https://opendata.paris.fr/>

- Une étude sur l'exposition au NO₂ et PM_{2.5} à Paris : <https://www.data.gouv.fr/fr/datasets/qualite-de-lair-exposition-des-parisien-ne-s-au-no2-et-pm2-5/>

➤ **Pékin ou Shanghai :**

- China National Environmental Monitoring Centre (CNEMC) : données officielles sur la qualité de l'air. Accès au CSV ou à l'API. <https://www.cnemc.cn/en/>

➤ **Partout dans le monde :**

- World Air Quality Index (WAQI) : données sur la qualité de l'air pour de nombreuses villes à travers le monde, dont Pékin et Shanghai. On y accède également au format CSV ou via une API. <https://waqi.info/>

- OpenAQ : <https://openaq.org>

- Données QA par un fabricant de « purificateur d'air » : <https://www.iqair.com/fr/>